

지하철 접근성은 정말로 생존을 결정하는가?

서울시 청소년게임제공업 4,064개 업소의
생존 분석을 통한 입지 가설 검증

EDA로 좁혀낸 질문 하나.

RESEARCH QUESTION

오프라인 상권의 핵심인 ‘**고객 접근성**’ (역 거리·유동인구)이 실제 업소 생존을 결정짓는 유의미한 변수인가?

EDA에서 드러난 세 가지 신호

01 · 역 거리

통계적으로 유의,
실질적으론 미미.

8m

영업·폐업 업소 중앙값 차이
 $p = 0.04 \rightarrow$ 유의하지만
현장 해석적 의미 없음

02 · 유동인구

방향은 맞지만
경계선에서 기각.

0.0662

Mann-Whitney p-value
영업 업소 주변이 다소 많지만
단독으로는 폐업을 설명 못 함

03 · 시설면적

가장 강한 신호 —
접근성보다 면적.

×2.7

폐업 업소 면적 중앙값
 $p \approx 0 \rightarrow$
대형 업소일수록 위험 (인허가시기의 교란변수 가능성)

그래서, 단순 비교 대신 생존분석으로.

EDA만으로는 "얼마나 오래 살아남았는지"를 다룰 수 없습니다.
개업 시기와 면적이라는 교란변수를 통제한 채, 시간 축에서 다시 묻습니다.

01

오기 쉬운가,
'버텨낼 수 있는가'

접근성 지표의 한계를 보완하고자 공급 측면의 '경쟁업소수' 변수를 추가 투입하여
분석 다각화를 시도합니다.

02

개업 시점이 다르면
'영업중'은 같은 의미가 아니다

2007년 개업과 2024년 개업을 같은 '영업중'으로 묶으면 노출 시간이 사라집니다.
→ 시간을 명시적으로 모델에 넣어야 합니다.

03

'아직 살아있는' 업소도
분석에서 버릴 수 없다

관측 종료 시점에 영업 중인 업소는 중도절단(censoring)으로 처리하면
정보를 잃지 않고 모델에 사용할 수 있습니다. (분석 기준일: 2026.04.09)

04

교란변수를 통제한 채
접근성만 떼어내고 싶다


Kaplan-Meier로 그룹 간 생존곡선 비교
→ Cox 모델로 면적·개업연도·경쟁을 통제한 뒤 접근성의 순효과(HR)를 추정합니다.

먼 곳과 가까운 곳, 정말로 다르게 살아남는가?


Kaplan-Meier는 '시간이 지나면서 몇 %가 살아남는지'를 그룹별로 그려보고, 두 곡선이 통계적으로 다른지(Log-rank test) 판정하는 방법입니다.

생존곡선 — 인허가 시기별·접근성 그룹별

1기 (2007~2015) 접근성 그룹별 생존 곡선



2기 (2016~2023) 접근성 그룹별 생존 곡선



— 고접근성(역500m 이내, 유동인구多) — 저접근성(역500m 초과, 유동인구 少)

두 곡선이 거의 겹친다 - 접근성만으로는 생존을 나타내지 못합니다.

RESULT

두 시기 모두
귀무가설을 기각하지 못함.

1기 (2007~2015) $p = 0.6306$

2기 (2016~2023) $p = 0.4768$

개업 시기를 나눠도 그룹 간 생존 확률 차이는 통계적으로 의미 없는 수준.

다음 단계 → Cox 모델로 다변량 통제.

※ 2024년 이후 개업한 544개 업소 중 폐업은 13건뿐
— 아직 결과를 지켜볼 시간이 충분하지 않아 분석에서 제외

다른 조건을 모두 똑같이 했을 때, 접근성은?

Cox 모델은 여러 변수를 동시에 넣고, ‘다른 조건이 같을 때 이 변수가 하나 변할 때마다 폐업 위험을 몇 배(HR)로 바꾸는지’를 추정합니다.

VARIABLE	HR	95% CI	p-value	SIGNIFICANCE	해석
인허가 연도 개업시점	1.05	1.04 ~ 1.06	< 0.005	통계적 유의	교란변수 가능성 — 통제변수로 이해
시설면적 m²	1.00	1.00 ~ 1.01	< 0.005	통계적 유의	교란변수 가능성 — 통제변수로 이해 (면적 1m² 증가당 HR은 미미하지만, EDA에서 확인된 폐업·영업중 증감값 차이를 고려하면 누적 효과는 실질적임)
경쟁 업소 수 반경내	1.00	1.00 ~ 1.01	= 0.01	통계적 유의	경쟁 1개 증가 시 폐업 위험 소폭 증가
최근접 역 거리 m	≈ 1.00	-	= 0.71	기각	
평균 승하차 인원 유동인구	≈ 1.00	-	= 0.86	기각	
500m 내 역 수 개	1.04	0.99~1.09	= 0.10	기각	

※ Concordance Index: 0.53 → 모델 전체의 예측력은 낮음.
"이 변수가 영향을 준다"와 "이 모델로 폐업을 예측할 수 있다"는 별개의 질문.


HR (위험비): exp(coef) 값, 1보다 크면 폐업 위험 증가
95% CI: 신뢰구간, 1을 포함하면 위험도 영향이 유의미하지 않음

분류모델: 폐업을 예측할 수 있는가, 그리고 접근성은?

SMOTE 적용 시 오히려 성능이 저하되어(클래스 0 recall 0.01),
원본 데이터 분포를 유지하면서 클래스 불균형을 보정하기 위해 `class_weight='balanced'` 방식을 채택했습니다.

Logistic Regression


• ROC-AUC	0.8290
• 클래스 0 recall (영업중)	0.86
• 클래스 1 recall (폐업)	0.68
• Accuracy	0.71



두 클래스 균형 있게 예측.

Random Forest

• ROC-AUC	0.8397
• 클래스 0 recall (영업중)	0.11
• 클래스 1 recall (폐업)	0.98
• Accuracy	0.87



사실상 전부 폐업으로 예측하는 편향 모델.

최종 모델 채택 : 로지스틱 회귀

Confusion Matrix


로지스틱 회귀 (영업 중 Recall: 0.86)

	예측 0	예측 1
실제 0 (영업중)	75	12
실제 1 (폐업)	187	401

랜덤 포레스트 (영업중 Recall: 0.11)

	예측 0	예측 1
실제 0 (영업중)	10	77
실제 1 (폐업)	10	578

Precision-Recall Curve



RESULT

최종 모델 :
로지스틱 회귀 채택

WHY ?

두 모델의 ROC-AUC (0.829 vs 0.840) 와 PR-AUC (0.967 vs 0.971)는 유사하나, 랜덤포레스트의 영업중 업소 recall이 0.11 → 사실상 전부 폐업으로 예측하는 모델

로지스틱 회귀는 랜덤포레스트보다 두 클래스 모두 균형 있게 예측하여 (recall 0.86 / 0.68) 실용적 관점에서 최종 채택.

살아남는 가게는 '언제·얼마나·옆에 누구'가 결정한다.

유의했던 세 변수의 분석 결과를 사람의 말로 풀어내 봅니다.

FINDING 01 · 언제

늦게 열수록 폐업 위험이
통계적으로 높게 나타남.

+5%

개업일 1년 늦을수록 폐업 위험 (HR = 1.05)

인허가 연도: 이미 기존 업소들이 자리를 잡고 포화된
시장의 성숙도와 진입 시점이 생존을 가르는 첫 번째
기준.

FINDING 02 · 얼마나

큰 매장일수록
오래 못 버틴다.

×2.7

폐업 업소 면적이 영업중 대비

시설 면적(Size): 폐업 업소의 면적 중앙값이 영업 대비
2.7배 큼. 고정비와 임대료 부담은 생존의 가장 큰 적.

FINDING 03 · 옆에 누구

옆집이 많아지면,
내 손님은 줄어든다.

p = 0.01

경쟁업소 수 → 유의한 위험요인

경쟁업소수(Comp): 유동인구 자체보다 중요한 건 그
수요를 나누어 갖는 경쟁자의 밀도. 유동인구보다
'수요를 나누는 경쟁자'가 더 결정적인 변수.

※ 경쟁업소수는 현재 시점 기준 — 시점 불일치 한계는 Slide 10 참조

SO WHAT?

접근성은 사라진 것이 아니라, 이미 모두가 가져간 '기본값'이 되었다.

왜 접근성이 유의미하지 않았을까?

가설을 의심하기 전에, 우리 데이터가 '어떻게 만들어졌는지'부터 의심해야 합니다.

데이터는 이미 '역세권'에 쏠려 있다


분석 대상 4,064개 업소 — 최근접 역까지의 거리 분포

67.8%

역에서 500m 이내

32.2%

500m 초과



지도 예시: 역세권 밀집 지역(강남구 일대)

CORE ARGUMENT

'접근성 좋은 곳만 모은 데이터'에서 접근성의 차이가 보일 리 없다.

01 · 자기선택 편향 (self-selection)

청소년게임제공업은 본래 역세권을 '선택'해서 들어갑니다.
수집한 데이터는 이미 이 선택의 결과만 보여줍니다.

02 · 범위 제한 (range restriction)

비교 대조군이 사라진 좁은 구역에서 회귀 계수는 0으로 수렴.
변수 자체가 의미가 없어서가 아니라, 변별력 특이 사라진 것 입니다.

03 · 그러면 무엇이 남는가

'다 같이 좋은 입지' 위에서 승부는 결국 개업시점·면적·경쟁 밀도로 갈렸습니다. Cox의 결과는 '남은 변수들'의 영향력을 뒷받침합니다.

모델이 못 보는 것, 그리고 다음에 봐야 할 것.

LIMITATIONS · 한 계

01

설명력이 낮다 — C-Index 0.53

현재 변수 구성만으로는 폐업 위험을 충분히 설명하지 못하는 한계

02

시점 불일치 — '오늘의 유동인구'로 '과거 폐업'을 본 셈

경쟁업소·승하차 인원은 최신 시점 기준. 폐업이 일어났던 그 시점의 환경과 어긋남.

03

교란변수 통제 — 통제변수로 투입했으나 인과관계 해석은 제한적

Cox에서 통제변수로 투입했으나 인허가연도·시설면적은 교란변수 가능성이 있어
순수한 인과관계 해석이 어려움

04

선택 편향 — 표본 자체의 쏠림

비역세권 업소가 부족 → 접근성 변수의 변별력이 구조적으로 제한됨.

NEXT STEPS · 보 완



임대료 · 상권 유형 · 프랜차이즈 변수 추가



연도별 유동인구 데이터 확보,
현재 단면이 아닌 시계열 기반 경쟁 강도 반영



시기별 층화 분석 등 추가 통제 방안 검토 필요



비역세권 지역과의 비교 분석으로 접근성 효과 재검증

‘접근성 좋은 곳에 차리면 오래 간다’는 직관은 — 절반만 맞다.

FACT

접근성은 생존을 가르지 못했다.

KM·Cox·분류모델 분석 결과 — 세 가지 분석 모두에서 역
거리·유동인구는 유의하지 않았음.

REASON

이미 모두가 역세권에 모여있다.

업소67.8%가 500m 이내에 분포
— 변수의 변별력이 사라진 '선택 편향' 구조.

WHAT MATTERS

개업 시점·면적·경쟁 밀도.

'좋은 입지'보다 '좋은 타이밍'과 적정 규모가 생존을 결정함.

THANK YOU

감사합니다.

<https://github.com/eunasim92-cmd/datamining>